

STAJ PROGRAMI

4 Haftalık Makine Öğrenmesi Staj Programı

Proje Adı	Eco-Driving & Fuel Consumption Prediction
Süre	4 Hafta

Ana hedef

Sürüş davranışlarından yakıt tüketimini tahmin eden bir makine öğrenmesi modeli geliştirmek.

Programın Amacı

Gerçek bir makine öğrenmesi projesini baştan sona doğru metodolojiyle yürütmek.

Bu staj programının amacı, gerçek bir makine öğrenmesi projesinin baştan sona nasıl yürütüldüğünü öğrenmektir.

PROGRAM SONUNDA UYGULANMASI BEKLENEN SÜREÇLER

Veri ve Modelleme	Değerlendirme ve Ürünleştirme
• Veriyi anlama • Veri analizi • Veri temizleme • Makine öğrenmesi modeli geliştirme • Model karşılaştırma • Feature engineering	• Model değerlendirme • Error analysis • Model explainability • API geliştirme • Teknik dokümantasyon • Final proje sunumu

Programın ana odağı

Yüksek bir model skoru tek başına yeterli değildir; model seçimi, hata davranışı, veri limitleri ve gerçek dünya kullanımı teknik olarak açıklanabilmelidir.

KULLANILACAK TEKNOLOJİLER

Ana teknolojiler	Opsiyonel
• Python • Pandas • NumPy • Matplotlib • Scikit-learn • Jupyter Notebook • Git • FastAPI • Pytest	• XGBoost • LightGBM • CatBoost • SHAP

Genel Çalışma Kuralları

Staj boyunca çalışma biçimi ve teslim disiplini.

1. Yapılan çalışmalar Git repository üzerinden iletilmelidir.
2. Tek seferde toplu commit yerine düzenli commit atılmalıdır.
3. Kullanılan yöntemler yalnızca uygulanmamalı, neden kullanıldığı açıklanmalıdır.
4. Kodların mümkün olduğunca okunabilir ve modüler olması beklenmektedir.
5. Notebook içerisinde yapılan çalışmalar final aşamasında Python scriptlerine taşınmalıdır.
6. Her hafta sonunda yapılan çalışmalar kısa bir sunum ile anlatılmalıdır.
7. Hazır kodların doğrudan kopyalanması yerine kullanılan yöntemlerin mantığı anlaşılmalıdır.
8. Bir problemle karşılaşıldığında önce araştırma yapılması beklenmektedir.

4 HAFTALIK YOL HARITASI

1. Hafta	Dataset'i Anlama ve EDA	Veriyi tanıma, kalite kontrolü, ilişkiler, outlier ve leakage
2. Hafta	Model Development	Train/validation/test, baseline, tree/boosting modeller, karşılaştırma
3. Hafta	Feature Engineering & Explainability	Yeni feature'lar, tuning, importance ve error analysis
4. Hafta	Uygulamaya Dönüştürme	Refactoring, prediction pipeline, FastAPI, test, dokümantasyon, sunum

1. HAFTA | Dataset'i Anlama ve Exploratory Data Analysis

Gün 1

Proje ve Dataset Tanıma

Haftanın hedefi

Makine öğrenmesi modeli geliştirmeden önce dataset'i anlamak ve veri içerisindeki ilişkileri keşfetmek.

YAPILACAK ÇALIŞMALAR

- Proje gereksinimlerini oku.
- Dataset'i indir.
- Python environment oluştur.
- Gerekli kütüphaneleri kur.
- Git repository oluştur.
- Dataset'i Pandas ile yükle.
- Dataset içerisindeki kolonları incele.

ARAŞTIRILMASI GEREKEN SORULAR

- Dataset kaç satırdan oluşuyor?
- Kaç kolon bulunuyor?
- Kolonların veri tipleri nedir?
- Target değişken hangisidir?
- Feature değişkenleri hangileridir?

GÜN SONU ÇIKTISI

README.md
requirements.txt
notebooks/01_data_understanding.ipynb

1. HAFTA | Dataset'i Anlama ve Exploratory Data Analysis

Gün 2

Data Quality Analysis

DATASET ÜZERİNDE YAPILACAK KONTROLLER

- Missing value
- Duplicate
- Data type problemleri
- Minimum ve maximum değerler
- Anormal değerler
- Outlier olabilecek değerler

HER KOLON İÇİN İNCELENECEK TEMEL İSTATİSTİKLER

- Mean
- Median
- Standard deviation
- Minimum
- Maximum
- Percentile

Gün sonu sorusu

Dataset içerisindeki hangi değerler veri kalitesi açısından problem oluşturabilir?

1. HAFTA | Dataset'i Anlama ve Exploratory Data Analysis

Gün 3

Exploratory Data Analysis

TARGET

fuel_consumption

Target değişkeni detaylı olarak incelenmelidir.

TARGET İLE İLİŞKİSİ ANALİZ EDİLECEK FEATURE'LAR

- rpm_variation
- harsh_braking_count
- idling_time
- acceleration_smoothness

HAZIRLANACAK GRAFİKLER

- Histogram
- Scatter plot
- Boxplot
- Correlation heatmap

Beklenti

Grafik çizmek yeterli değildir. Her grafiğin altında kısa bir yorum bulunmalıdır.

Örnek yorum

Idling time yükseldikçe fuel consumption değerinin arttığı gözlemlenmektedir.

1. HAFTA | Dataset'i Anlama ve Exploratory Data Analysis

Gün 4

Outlier ve Leakage Analysis

Dataset'teki sıra dışı değerler incelenmelidir.

OUTLIER ANALIZI İÇİN KULLANILABİLECEK YÖNTEMLER

- IQR
- Z-score
- Percentile
- Boxplot

AYRICA DETAYLI İNCELENECEK KOLON

eco_score

CEVAPLANMASI GEREKEN SORULAR

- eco_score neyi temsil ediyor?
- Nasıl oluşturulmuş olabilir?
- Model için feature olarak kullanılması doğru olur mu?
- Data leakage nedir?

1. HAFTA | Dataset'i Anlama ve Exploratory Data Analysis

Gün 5

Hafta 1 Review

Kısa sunum

10-15 dakika

SUNUM KONUSU

Dataset'ten öğrendiğim en önemli 5 şey

SUNUMDA ANLATILMASI GEREKENLER

- Dataset
- Data quality
- Önemli grafikler
- Feature ilişkileri
- Outlier'lar
- Leakage değerlendirmesi

HAFTA 1 TESLİMATI

```
notebooks/  
├── 01_data_understanding.ipynb  
└── 02_eda.ipynb  
  
reports/  
└── eda_report.md
```

2. HAFTA | Machine Learning Model Development

Gün 6

Train / Validation / Test

Haftanın hedefi

Makine öğrenmesi model geliştirme sürecini öğrenmek ve farklı algoritmaları karşılaştırmak.

DATASET BÖLÜNMESİ

Train
Validation
Test

ÖRNEK ORANLAR

Train: %70
Validation: %15
Test: %15

ARAŞTIRILACAK KAVRAMLAR

- Train set
- Validation set
- Test set
- Overfitting
- Data leakage

Gün sonu sorusu

Model seçimi sırasında test dataset neden kullanılmamalıdır?

2. HAFTA | Machine Learning Model Development

Gün 7

Baseline Model

İlk olarak basit bir baseline oluşturulmalıdır.

BASELINE ÖRNEĞİ

DummyRegressor

Daha sonra aşağıdaki model geliştirilmelidir.

Linear Regression

DEĞERLENDİRME METRİKLERİ

- MAE
- RMSE
- R^2

Araştırılması gereken soru

Baseline model kullanmak neden önemlidir?

2. HAFTA | Machine Learning Model Development

Gün 8

Tree Based Models

EN AZ İKİSİ DENENMELİDİR

- Decision Tree
- Random Forest
- Extra Trees

HER MODEL İÇİN HESAPLANMALIDIR

- Train score
- Validation score
- MAE
- RMSE
- R^2

Kontrol noktası

Train ve validation skorlarını birlikte değerlendir; yalnızca tek bir metriğe göre karar verme.

2. HAFTA | Machine Learning Model Development

Gün 9

Boosting Models

EN AZ BİRİ KULLANILMALIDIR

- Gradient Boosting
- XGBoost
- LightGBM
- CatBoost

DENENEN TÜM MODELLER KARŞILAŞTIRILMALIDIR

Model	MAE	RMSE	R ²
Baseline	...	...	...
Linear Regression	...	...	...
Random Forest	...	...	...
Gradient Boosting	...	...	...

2. HAFTA | Machine Learning Model Development

Gün 10

Model Comparison Review

STAJYER AŞAĞIDAKİ SORULARA CEVAP VERMELİDİR

- En başarılı model hangisidir?
- Neden daha iyi sonuç vermiş olabilir?
- Train ve validation skorları arasında fark var mı?
- Overfitting var mı?
- Hangi metriği daha önemli görüyorsunuz?
- Sadece R^2 kullanmak yeterli midir?

HAFTA 2 TESLİMİ

```
notebooks/  
├── 03_baseline.ipynb  
└── 04_model_comparison.ipynb  
  
src/  
└── train.py
```

3. HAFTA | Feature Engineering, Model Improvement ve Explainability

Gün 11

Feature Engineering

Haftanın hedefi

Modeli sadece algoritma değiştirerek değil, veriyi daha iyi temsil ederek geliştirmeyi öğrenmek.

En az 3 yeni feature oluşturulmalıdır. Feature'lar rastgele oluşturulmamalıdır.

Her feature için açıklanmalıdır

Bu feature'ın yakıt tüketimini tahmin etmeye neden yardımcı olabileceğini düşünüyorum?

ÖRNEK FIKIRLER

```
aggressive_driving_index  
idle_braking_interaction  
driving_smoothness_indicator
```

3. HAFTA | Feature Engineering, Model Improvement ve Explainability

Gün 12

Feature Engineering Experiment

İKİ MODEL KARŞILAŞTIRILMALIDIR

Model A	Model B
Sadece original feature'lar.	Original + yeni oluşturulan feature'lar.

Cevaplanması gereken soru

Feature engineering model performansını artırdı mı?

Eğer artırmadıysa neden artırmamış olabileceği tartışılmalıdır.

3. HAFTA | Feature Engineering, Model Improvement ve Explainability**Gün 13**

Hyperparameter Tuning

En başarılı model seçilmelidir.

TUNING YÖNTEMİ

GridSearchCV
veya
RandomizedSearchCV

Cross-validation kullanılmalıdır.

Gün sonu sorusu

Hyperparameter tuning ile model training arasındaki fark nedir?

3. HAFTA | Feature Engineering, Model Improvement ve Explainability

Gün 14

Feature Importance

Final model için feature importance analizi yapılmalıdır.

KULLANILABİLECEK YÖNTEMLERDEN BİRİ

- Random Forest Feature Importance
- Permutation Importance
- SHAP

Cevaplanması gereken soru

Modelin tahminini en çok hangi feature etkiliyor?

3. HAFTA | Feature Engineering, Model Improvement ve Explainability

Gün 15

Error Analysis

Validation dataset üzerinde modelin en kötü tahminleri incelenmelidir.

ÖRNEK ANALİZ

En yüksek hataya sahip 20 prediction

ARAŞTIRILMASI GEREKEN SORULAR

- Bu kayıtların ortak özelliği var mı?
- Model yüksek tüketim değerlerinde daha mı kötü?
- Belirli sürüş davranışlarında hata artıyor mu?
- Modelde eksik bir feature olabilir mi?

HAFTA 3 TESLİMATI

```
notebooks/  
├── 05_feature_engineering.ipynb  
├── 06_model_tuning.ipynb  
└── 07_error_analysis.ipynb  
  
src/  
├── features.py  
├── evaluation.py  
└── train.py  
  
models/  
└── final_model.pkl
```

4. HAFTA | Modeli Uygulamaya Dönüştürme

Gün 16

Code Refactoring

Haftanın hedefi

Notebook içerisinde çalışan modeli tekrar kullanılabilir küçük bir ML servisine dönüştürmek.

Notebook içerisindeki kodlar Python scriptlerine ayrılmalıdır.

ÖNERİLEN YAPI

```
src/  
├── preprocessing.py  
├── features.py  
├── train.py  
├── predict.py  
└── evaluation.py
```

Kod kalitesi

Kod tekrarları mümkün olduğunca azaltılmalıdır.

4. HAFTA | Modeli Uygulamaya Dönüştürme

Gün 17

Prediction Pipeline

Model kaydedilmelidir.

ÖRNEK MODEL DOSYASI

```
model.pkl
```

Daha sonra aşağıdaki gibi prediction fonksiyonu geliştirilmelidir.

```
predict_fuel_consumption(data)
```

Beklenti

Fonksiyon yeni bir sürüş kaydı aldığı anda yakıt tüketimi tahmini üretmelidir.

4. HAFTA | Modeli Uygulamaya Dönüştürme

Gün 18

FastAPI

FastAPI kullanılarak aşağıdaki endpoint geliştirilmelidir.

```
POST /predict
```

ÖRNEK INPUT

```
{
  "rpm_variation": 850,
  "harsh_braking_count": 7,
  "idling_time": 12.4,
  "acceleration_smoothness": 0.42
}
```

ÖRNEK OUTPUT

```
{
  "predicted_fuel_consumption": 8.35
}
```

4. HAFTA | Modeli Uygulamaya Dönüştürme

Gün 19

Testing ve Documentation

API İÇİN EN AZ 5 TEST HAZIRLANMALIDIR

- valid prediction
- missing parameter
- invalid parameter type
- negative idling time
- model loading

README İÇERİSİNDE BULUNMALIDIR

- Proje amacı
- Dataset
- EDA sonuçları
- Modeller
- Final model
- Metrics
- Kurulum
- Training
- Prediction
- API kullanımı
- Model limitleri

4. HAFTA | Modeli Uygulamaya Dönüştürme

Gün 20

Final Presentation

Final sunumu

20-30 dakika

SUNUM SIRASI

9. Problem
10. Dataset
11. EDA
12. Data leakage
13. Baseline
14. Model comparison
15. Feature engineering
16. Final model
17. Error analysis
18. Feature importance
19. API demo
20. Limitations
21. Future improvements

Final beklenti

Sunum sonunda canlı prediction demo yapılması beklenmektedir.

Final Repository

Program sonunda projenin ulaşması beklenen yaklaşık dosya yapısı.

```
eco-driving-ml/
├── README.md
├── requirements.txt
├── .gitignore
├── data/
├── notebooks/
│   ├── 01_data_understanding.ipynb
│   ├── 02_eda.ipynb
│   ├── 03_baseline.ipynb
│   ├── 04_model_comparison.ipynb
│   ├── 05_feature_engineering.ipynb
│   ├── 06_model_tuning.ipynb
│   └── 07_error_analysis.ipynb
├── src/
│   ├── preprocessing.py
│   ├── features.py
│   ├── train.py
│   ├── predict.py
│   └── evaluation.py
├── models/
│   └── final_model.pkl
├── api/
│   └── main.py
├── tests/
│   └── test_api.py
└── reports/
    └── final_report.md
```

Değerlendirme Kriterleri

Toplam 100 puan üzerinden değerlendirme dağılımı.

Alan	Puan
Veri analizi ve EDA	15
ML yaklaşımı	15
Model comparison	10
Feature engineering	10
Model evaluation	10
Error analysis	10
Data leakage farkındalığı	10
Kod kalitesi	5
API ve testing	5
Documentation	5
Final sunumu	5
Toplam	100

PROGRAMIN ANA BEKLENTİSİ

Bu staj programında amaç yalnızca yüksek model skoru elde etmek değildir.

- Model neden bu sonucu veriyor?
- Neden bu modeli seçtin?
- Model nerelerde hata yapıyor?
- Dataset'in limitleri nelerdir?
- Data leakage nasıl oluşabilir?
- Model gerçek dünyada nasıl kullanılabilir?
- Production ortamına taşımak için başka nelere ihtiyaç vardır?

Ana hedef

Bir makine öğrenmesi problemini baştan sona doğru metodoloji ile çözebilmek ve geliştirdiğin sistemi teknik olarak açıklayabilmek.